

MÓDULO 2 · MATERIAL 5

Preparación y Limpieza de Datos en Machine Learning

Material teórico · Calidad de datos, preprocesamiento, codificación, escalado y prevención de Data Leakage

Descripción

Un modelo de Machine Learning aprende a partir de los datos que recibe. Si esos datos contienen valores faltantes, duplicados, errores, formatos inconsistentes o variables en escalas diferentes, el modelo puede aprender patrones poco confiables. Por esta razón, la preparación de los datos es una etapa fundamental del flujo de trabajo.

Objetivos de aprendizaje

- Comprender por qué la calidad de los datos afecta el entrenamiento y la evaluación de un modelo.
- Identificar datos faltantes, duplicados, valores inválidos y valores atípicos.
- Aplicar estrategias básicas de limpieza e imputación.
- Diferenciar variables numéricas y categóricas.
- Comprender Label Encoding y One-Hot Encoding.
- Comprender la Normalización Min-Max y la Estandarización Z-score.
- Dividir los datos en entrenamiento y prueba de forma adecuada.
- Reconocer y prevenir la fuga de información o Data Leakage.

1. ¿Qué significa preparar los datos?

La preparación de datos consiste en transformar un conjunto de información original en una representación adecuada para un algoritmo de Machine Learning. No significa modificar los datos arbitrariamente: implica detectar problemas, documentar decisiones y aplicar transformaciones justificadas.

Un flujo habitual incluye cargar los datos, inspeccionarlos, limpiarlos, transformarlos, dividirlos en entrenamiento y prueba y finalmente preparar las variables para el modelo.

2. Calidad de los datos

La calidad puede analizarse desde diferentes dimensiones: completitud, consistencia, validez, unicidad y coherencia con el dominio del problema.

Una columna puede no contener valores nulos y aun así presentar datos incorrectos. Por ejemplo, una edad de 250 no es un dato faltante, pero es inválida para un problema que representa edades humanas.

3. Datos faltantes

Un dato faltante puede aparecer como NaN, None, una celda vacía u otra marca definida por el sistema.

Antes de decidir qué hacer, conviene medir cuántos faltantes existen y en qué variables aparecen.

Algunas estrategias son eliminar registros, eliminar una variable, imputar con media o mediana en variables numéricas o utilizar la moda para variables categóricas.

La mediana suele ser más resistente a valores extremos que la media.

4. Registros duplicados

Un duplicado es un registro repetido que puede representar la misma observación. La duplicación puede provocar que determinados casos tengan un peso artificialmente mayor durante el entrenamiento.

En pandas se pueden detectar con `duplicated()` y eliminar con `drop_duplicates()`.

Antes de eliminar registros es necesario comprobar que realmente representan observaciones repetidas.

5. Valores incorrectos y reglas de dominio

Una regla de dominio establece qué valores son razonables para una determinada variable.

Por ejemplo, una edad humana debe encontrarse dentro de un rango coherente con el problema. Una temperatura, una cantidad o un porcentaje también pueden tener restricciones.

Un valor inválido no debe confundirse automáticamente con un outlier estadístico.

6. Valores atípicos u outliers

Un outlier es una observación que se aleja considerablemente del comportamiento general de los datos.

Puede representar un error, un caso poco frecuente pero real o una característica importante del fenómeno estudiado.

Una técnica habitual es el rango intercuartílico (IQR):

$$\text{IQR} = Q3 - Q1$$

$$\text{Límite inferior} = Q1 - 1.5 \times \text{IQR}$$

$$\text{Límite superior} = Q3 + 1.5 \times \text{IQR}$$

La detección estadística no demuestra por sí sola que el dato sea incorrecto. Siempre debe considerarse el contexto.

7. Variables numéricas y categóricas

Las variables numéricas representan cantidades que pueden utilizarse mediante operaciones matemáticas, como edad, horas de estudio o precio.

Las variables categóricas representan clases o categorías, como modalidad, departamento o tipo de curso.

Muchos algoritmos necesitan transformar las categorías a representaciones numéricas antes del entrenamiento.

8. Label Encoding

Label Encoding asigna un número a cada categoría.

Por ejemplo:

Presencial $\rightarrow$ 0 Virtual $\rightarrow$ 1

Puede resultar apropiado en determinadas situaciones, especialmente cuando las categorías poseen un orden real.

Sin embargo, si las categorías son nominales y no tienen orden, la codificación numérica puede generar una relación matemática que en realidad no existe.

9. One-Hot Encoding

One-Hot Encoding crea una columna binaria para cada categoría.

Si una variable Modalidad contiene Presencial y Virtual, se pueden generar:

Modalidad_Presencial Modalidad_Virtual

Para cada registro, una de las columnas tendrá valor 1 y las restantes tendrán valor 0.

Esta representación evita establecer un orden numérico artificial entre categorías nominales.

10. Escalado de variables

Algunos algoritmos son sensibles a la escala de las variables.

Por ejemplo, una variable que toma valores entre 0 y 1 y otra que toma valores entre 0 y 100000 no se encuentran en una escala comparable.

Dos técnicas frecuentes son la Normalización Min-Max y la Estandarización Z-score.

11. Normalización Min-Max

La normalización Min-Max transforma una variable para llevarla habitualmente al intervalo [0, 1].

$$x' = (x - \text{mínimo}) / (\text{máximo} - \text{mínimo})$$

Es útil cuando se desea trabajar dentro de un rango determinado.

Los valores extremos pueden influir en el mínimo y máximo utilizados para realizar la transformación.

12. Estandarización Z-score

La estandarización expresa cada valor en relación con la media y el desvío estándar.

$$z = (x - \text{media}) / \text{desvío estándar}$$

Una variable estandarizada presenta aproximadamente media 0 y desvío estándar 1 dentro del conjunto utilizado para ajustar la transformación.

13. División de los datos

Una división habitual separa los datos en entrenamiento y prueba.

El conjunto de entrenamiento se utiliza para aprender los parámetros del modelo.

El conjunto de prueba se reserva para estimar cómo se comporta el modelo frente a datos que no utilizó durante el entrenamiento.

También puede utilizarse un conjunto de validación o validación cruzada.

14. Data Leakage o fuga de información

Existe Data Leakage cuando información que no debería estar disponible durante el entrenamiento termina influyendo en el modelo.

Un error frecuente consiste en calcular la media, mediana, escalado o codificación utilizando todo el dataset antes de dividirlo.

La regla práctica es:

Primero se separan los datos.

Después se ajustan las transformaciones utilizando únicamente el conjunto de entrenamiento.

Finalmente se aplican esas transformaciones al conjunto de prueba.

15. Flujo recomendado

Un flujo básico y seguro es:

1. Cargar los datos. 2. Explorar estructura, tipos y calidad. 3. Separar variables predictoras y objetivo. 4. Dividir los datos en entrenamiento y prueba. 5. Ajustar imputación, codificación y escalado con entrenamiento. 6. Aplicar las transformaciones al entrenamiento y a la prueba. 7. Entrenar el modelo. 8. Evaluar sobre los datos de prueba.

En proyectos reales, scikit-learn permite organizar estas operaciones mediante Pipeline y ColumnTransformer.

16. Actividad de identificación

Analiza la siguiente tabla y responde las preguntas.

Nombre	Edad	Departamento	Horas de estudio
Ana	20	Salto	8
Luis	22	Artigas	5
Marta	Faltante	Salto	7
Juan	21	Artigas	3
Juan	21	Artigas	3
Pedro	250	Salto	4

- Identifica un dato faltante.
- Identifica un registro duplicado.
- Identifica un valor que debería validarse mediante una regla de dominio.
- Indica qué variables son numéricas y cuál es categórica.
- Propón una estrategia de limpieza para cada problema.

17. Actividad práctica con Python

Ejecuta los archivos Python incluidos con este material. Observa las tablas antes y después de cada transformación y explica qué cambió y por qué.

18. Preguntas de autoevaluación

- ¿Por qué no conviene eliminar automáticamente todos los registros que contienen valores faltantes?
- ¿Cuál es la diferencia entre un valor inválido y un outlier?
- ¿Cuándo puede ser problemática una codificación Label Encoding?
- ¿Qué diferencia existe entre Min-Max y Z-score?
- ¿Por qué una transformación calculada con todo el dataset puede producir Data Leakage?
- ¿Qué información debe utilizarse para ajustar un escalador antes de evaluar el modelo?

19. Actividad integradora

Primer proyecto de preparación de datos

Utiliza un dataset pequeño relacionado con estudiantes, cursos, ventas, productos u otra temática. Identifica al menos un problema de calidad, justifica su tratamiento, prepara las variables para Machine Learning y documenta cada decisión. El resultado debe incluir el dataset original, el dataset preparado, el código Python y una breve explicación de las transformaciones realizadas.