

MÓDULO 2 · MATERIAL 4

Evaluación de modelos de Machine Learning

Material Teórico • Matriz de Confusión, Precisión, Recall y Métricas de Regresión

Descripción: Entrenar un modelo no significa automáticamente que sus resultados sean correctos o útiles. Un modelo puede realizar muchas predicciones acertadas y, al mismo tiempo, cometer errores importantes. En este material aprenderemos a analizar las predicciones de clasificación mediante la matriz de confusión, precisión y recall, así como métricas fundamentales para evaluación de regresión (MAE y MSE).

Objetivos de aprendizaje:

- Comprender la importancia de evaluar modelos y analizar los tipos de errores.
- Construir e interpretar una Matriz de Confusión (TP, TN, FP, FN).
- Calcular e interpretar la Precisión y el Recall en problemas de clasificación.
- Entender el impacto del umbral de decisión en clasificación.
- Comprender las métricas MAE y MSE para evaluación de modelos de regresión.

1. ¿Por qué evaluar un modelo?

Si desarrollamos un modelo para detectar spam, el sistema evalúa cada correo y emite una predicción. Para saber si es correcto, debemos comparar la predicción con el resultado real:

Resultado Real	Predicción del Modelo	¿Acertó?
Spam	Spam	Sí
Spam	No spam	No
No spam	Spam	No
No spam	No spam	Sí

Idea fundamental: Un modelo no es bueno simplemente porque produce predicciones. Debemos comprobar qué tan acertadas son sus predicciones, qué tipo de errores comete y cuál es la gravedad de esos errores según el problema.

2. Matriz de Confusión y Cuatro Resultados Posibles

En clasificación binaria (Positivo / Negativo), la combinación de la realidad y la predicción genera cuatro situaciones posibles:

Matriz de Confusión	Predicción Positiva	Predicción Negativa
Real Positivo	TP (Verdadero Positivo) Acertó el caso positivo	FN (Falso Negativo) Se le escapó un positivo
Real Negativo	FP (Falso Positivo) Falsa alarma	TN (Verdadero Negativo) Acertó el caso negativo

Detalle de conceptos:

- **TP (True Positive):** Es positivo y predice positivo. *Ejemplo:* Era spam y lo detectó como spam.
- **TN (True Negative):** Es negativo y predice negativo. *Ejemplo:* Era un correo legítimo y lo clasificó como no spam.
- **FP (False Positive):** Es negativo pero predice positivo (falsa alarma). *Ejemplo:* Correo legítimo enviado a spam.

- **FN (False Negative):** Es positivo pero predice negativo (omisión). *Ejemplo:* Correo de spam que llegó a la bandeja de entrada.

3. Precisión (Precision) y Recall (Exhaustividad)

Supongamos que un modelo evalúa 10 correos: TP=3, FN=2, FP=3, TN=2. (Total = 10 casos).

Métrica	Fórmula	Cálculo de ejemplo	Interpretación
Precisión	$TP / (TP + FP)$	$3 / (3 + 3) = 0,50$ 50%	De todo lo que predijo como spam, solo la mitad realmente lo era.
Recall	$TP / (TP + FN)$	$3 / (3 + 2) = 0,60$ 60%	De todos los correos que realmente eran spam, logró detectar el 60%.

Diferencia clave: La *Precisión* penaliza los falsos positivos (evitar dar falsas alarmas), mientras que el *Recall* penaliza los falsos negativos (evitar dejar pasar casos positivos reales).

4. Umbral de Decisión (Threshold)

Muchos modelos no devuelven simplemente 'Sí' o 'No', sino una probabilidad (ej. 0,81). Por defecto se utiliza un umbral de 0,50. Si modificamos el umbral a 0,70, el modelo exigirá más certeza para decir 'Positivo', lo cual suele **increamentar la precisión** pero **disminuir el recall**.

5. Evaluación en Modelos de Regresión

En regresión predecimos valores numéricos (precios, temperaturas). No usamos matriz de confusión, sino métricas de error entre el valor real (y_i) y el predicho ($\hat{y}_i$):

Métrica	Fórmula	Características principales
MAE Error Absoluto Medio	$MAE = (1/n) \sum y_i - \hat{y}_i $	Promedia las diferencias absolutas. Es intuitivo y se expresa en las mismas unidades que la variable dependiente.
MSE Error Cuadrático Medio	$MSE = (1/n) \sum (y_i - \hat{y}_i)^2$	Eleva los errores al cuadrado. Penaliza con mucha mayor fuerza los errores grandes o atípicos.

Glosario de Conceptos Clave

Concepto	Definición
Matriz de Confusión	Tabla que organiza las predicciones de clasificación en TP, TN, FP y FN.
Precisión (Precision)	Proporción de positivos predichos que realmente eran positivos ($TP / [TP + FP]$).
Recall (Exhaustividad)	Proporción de casos positivos reales que el modelo logró detectar ($TP / [TP + FN]$).
Umbral (Threshold)	Puntuación de corte a partir de la cual una probabilidad se considera clase positiva.
MAE	Error Absoluto Medio. Promedio directo de los errores de predicción en regresión.
MSE	Error Cuadrático Medio. Promedio de los errores al cuadrado en regresión.