

MÓDULO 2 · MATERIAL 5

Actividades prácticas: Preparación y Limpieza de Datos

Consignas para trabajar con Python, pandas, NumPy y scikit-learn

Actividad 1 - Identificación de problemas

Observa la tabla presentada en el material teórico. Identifica datos faltantes, duplicados, valores inválidos y tipos de variables. Justifica cada respuesta.

Actividad 2 - Limpieza con pandas

Ejecuta 01_limpieza_y_calidad.py. Observa el dataset original y explica el efecto de cada operación: `drop_duplicates()`, validación de la edad e imputación con la mediana.

Actividad 3 - Codificación

Ejecuta 02_codificacion.py. Compara Label Encoding y One-Hot Encoding. Explica qué información representa cada columna generada y por qué una variable nominal no debería interpretarse automáticamente como ordinal.

Actividad 4 - Escalado

Ejecuta 03_escalado.py. Compara los resultados de Min-Max y Z-score. Explica qué ocurre con una variable que posee un valor extremo.

Actividad 5 - Entrenamiento y prueba

Ejecuta 04_division_y_leakage.py. Comprueba por qué las transformaciones deben ajustarse con los datos de entrenamiento y luego aplicarse al conjunto de prueba.

Actividad 6 - Actividad integradora

Primer proyecto de preparación de datos

Selecciona un dataset pequeño y comprensible. Puede ser de estudiantes, ventas, cursos, productos u otra temática relacionada con un problema de datos. El dataset debe contener al menos una variable numérica y una categórica.

Realiza las siguientes etapas:

1. Describe brevemente el dataset y su propósito.
2. Inspecciona las columnas y los tipos de datos.
3. Detecta valores faltantes y decide cómo tratarlos.
4. Detecta duplicados y justifica su eliminación o conservación.
5. Identifica al menos un posible valor inválido o atípico.
6. Codifica las variables categóricas cuando sea necesario.
7. Escala las variables numéricas utilizando una técnica adecuada.
8. Divide los datos en entrenamiento y prueba.
9. Explica cómo evitaste Data Leakage.
10. Entrega el código y una breve conclusión.

Producto a entregar

- Archivo Python (.py).
- Dataset utilizado (.csv u otro formato permitido).
- Dataset preparado, si corresponde.
- Breve informe con las decisiones tomadas.

Criterios de revisión

- El código se ejecuta sin errores.
- Las decisiones de limpieza están justificadas.
- Las variables están correctamente identificadas.
- Las transformaciones se aplican sin producir fuga de información.
- El estudiante puede explicar con sus palabras qué hizo y por qué.