

MÓDULO 1 • PIPELINE DE DATOS Y PREPARACIÓN PROFESIONAL

Exploración Avanzada de Datos (EDA)

Actividades prácticas — Pandas, Seaborn y YData Profiling

Propósito

Aplicar técnicas de Exploratory Data Analysis para conocer la estructura, calidad, distribución y relaciones presentes en un conjunto de datos antes del modelado.

Actividad 1. Reconocer un dataset

Observa el siguiente conjunto de datos hipotético:

Edad	Ingresos	Ciudad	Plan	Abandono
22	\$25000	Montevideo	Básico	No
35	\$52000	Canelones	Premium	No
41	\$61000	Montevideo	Premium	Sí
29	\$33000	Salto	Básico	No
52	\$72000	Montevideo	Premium	Sí

- ¿Cuántas variables contiene el dataset?
- ¿Cuáles son numéricas?
- ¿Cuáles son categóricas?
- ¿Cuál podría ser la variable objetivo?
- ¿Qué variables podrían utilizarse como características?

Actividad 2. Primer diagnóstico con Pandas

Crea un archivo Python y carga un dataset utilizando Pandas.

Realiza las siguientes operaciones:

- Mostrar las primeras cinco filas.
- Mostrar la cantidad de filas y columnas.
- Mostrar los nombres de las columnas.
- Mostrar los tipos de datos.
- Mostrar información general del dataset.
- Mostrar estadísticas descriptivas.

Código de referencia:

```
import pandas as pd

df = pd.read_csv('dataset.csv')

print(df.head())
print(df.shape)
print(df.columns)
print(df.dtypes)
df.info()
print(df.describe())
```

Actividad 3. Detectar problemas de calidad

Utilizando el mismo dataset, investiga:

- ¿Cuántos valores faltantes existen por columna?
- ¿Qué porcentaje de valores faltantes tiene cada variable?
- ¿Existen registros duplicados?
- ¿Hay variables con tipos de datos incorrectos?
- ¿Existen valores imposibles o sospechosos?

Utiliza como mínimo:

```
df.isnull().sum()
df.duplicated().sum()
df.info()
```

Actividad 4. Estadística descriptiva

Selecciona tres variables numéricas de tu dataset y analiza sus estadísticas descriptivas.

- ¿Cuál es el promedio?
- ¿Cuál es la mediana?
- ¿Cuál es el valor mínimo?
- ¿Cuál es el valor máximo?
- ¿Existe una diferencia importante entre media y mediana?
- ¿Qué podría indicar esa diferencia?

Actividad 5. Análisis de distribuciones

Selecciona una variable numérica y construye un histograma utilizando Seaborn.

```
import seaborn as sns
import matplotlib.pyplot as plt

sns.histplot(data=df, x='variable', kde=True)
plt.show()
```

Luego responde:

- ¿Dónde se concentra la mayor cantidad de observaciones?
- ¿La distribución parece simétrica?
- ¿Se observan valores extremos?

- ¿Hay algo que resulte inesperado?

Actividad 6. Detectar posibles outliers

Selecciona una variable numérica y construye un boxplot.

```
sns.boxplot(data=df, x='variable')  
plt.show()
```

Identifica si existen observaciones alejadas del resto.

Importante: no elimines los outliers. En esta actividad solo debes identificarlos y formular una posible explicación.

Actividad 7. Análisis de variables categóricas

Selecciona una variable categórica y analiza la cantidad de observaciones de cada categoría.

```
sns.countplot(data=df, x='categoria')  
plt.show()
```

- ¿Cuál es la categoría más frecuente?
- ¿Cuál es la menos frecuente?
- ¿Las categorías están equilibradas?
- ¿Podría existir un problema de desbalance?

Actividad 8. Explorar relaciones entre variables

Selecciona dos variables numéricas y crea un scatterplot.

```
sns.scatterplot(data=df, x='variable_1', y='variable_2')  
plt.show()
```

- ¿Parece existir alguna relación?
- ¿La relación parece positiva o negativa?
- ¿Existen grupos de observaciones?
- ¿Hay valores que se alejan del patrón general?

Actividad 9. Matriz de correlación

Calcula la matriz de correlación de las variables numéricas y represéntala mediante un heatmap.

```
corr = df.corr(numeric_only=True)  
  
sns.heatmap(corr, annot=True, cmap='coolwarm')  
plt.show()
```

Selecciona dos relaciones que te llamen la atención y explica qué significan.

Actividad 10. Generar un informe automático con YData Profiling

Instala la biblioteca si aún no está disponible:

```
pip install ydata-profiling
```

Luego genera un informe:

```
from ydata_profiling import ProfileReport
```

```
profile = ProfileReport(df, title='Reporte EDA')
profile.to_file('reporte_eda.html')
```

Abre el archivo HTML y compara los resultados automáticos con el análisis realizado manualmente.

Actividad 11. Interpretar, no solamente ejecutar

Una herramienta de análisis puede producir muchos resultados. El objetivo de esta actividad es aprender a interpretarlos.

Para tres hallazgos encontrados durante la EDA, completa:

Hallazgo	Evidencia	Interpretación	Acción posible

Actividad 12. EDA de un dataset de clientes

Realiza una exploración completa sobre un dataset de clientes o usuarios.

Tu análisis debe incluir como mínimo:

- Descripción del dataset.
- Cantidad de filas y columnas.
- Tipos de variables.
- Estadísticas descriptivas.
- Valores faltantes.
- Duplicados.
- Al menos un histograma.
- Al menos un boxplot.
- Al menos un gráfico categórico.
- Al menos un scatterplot.
- Matriz de correlación.
- Informe de YData Profiling.

- Cinco conclusiones relevantes.

Actividad Integradora — Informe EDA profesional

Consigna

Selecciona un dataset relacionado con un problema que pueda abordarse mediante Machine Learning. Realiza una Exploración Exploratoria de Datos completa y presenta un informe que permita comprender el estado del dataset antes del modelado.

El informe debe contener:

- 1. Descripción del problema y del dataset.
- 2. Cantidad de registros y variables.
- 3. Identificación de tipos de datos.
- 4. Análisis de valores faltantes.
- 5. Análisis de duplicados.
- 6. Estadística descriptiva.
- 7. Análisis de distribuciones.
- 8. Identificación de posibles outliers.
- 9. Análisis de variables categóricas.
- 10. Análisis de relaciones entre variables.
- 11. Matriz de correlación.
- 12. Informe generado con YData Profiling.
- 13. Principales hallazgos.
- 14. Problemas que deberían resolverse antes del modelado.

Autoevaluación

1. ¿Qué significa EDA?

Respuesta: Exploratory Data Analysis o análisis exploratorio de datos.

2. ¿Para qué sirve `df.info()`?

Respuesta: Para conocer estructura, columnas, valores no nulos y tipos de datos.

3. ¿Qué devuelve `df.shape`?

Respuesta: Una tupla con cantidad de filas y columnas.

4. ¿Qué permite observar un histograma?

Respuesta: La distribución de una variable numérica.

5. ¿Para qué sirve un boxplot?

Respuesta: Para analizar distribución, dispersión y posibles valores atípicos.

6. ¿Qué representa una correlación cercana a 1?

Respuesta: Una relación lineal positiva fuerte.

7. ¿Una correlación demuestra causalidad?

Respuesta: No. Correlación y causalidad son conceptos diferentes.

8. ¿Para qué sirve YData Profiling?

Respuesta: Para generar un informe automatizado de exploración de datos.

Cierre**Idea clave:**

Antes de entrenar un modelo de Machine Learning debemos comprender los datos con los que vamos a trabajar. La EDA permite transformar un dataset desconocido en información que puede ser analizada y utilizada para tomar decisiones fundamentadas.