

MÓDULO 1 • PIPELINE DE DATOS Y PREPARACIÓN PROFESIONAL

Limpieza e Imputación de Valores Faltantes

Actividades prácticas — Calidad de datos e imputación

Propósito

Aplicar técnicas de detección, análisis y tratamiento de valores faltantes utilizando Pandas y Scikit-learn, comprendiendo los riesgos de cada estrategia.

Actividad 1. Reconocer valores faltantes

Analiza el siguiente dataset hipotético:

Edad	Ingresos	Ciudad	Plan
22	25000	Montevideo	Básico
35		Canelones	Premium
	61000	Montevideo	Premium
29	33000		Básico
52	72000	Montevideo	

- Identifica todas las celdas con información faltante.
- ¿Qué porcentaje aproximado de datos falta en cada columna?
- ¿Eliminarías alguna fila? Justifica.
- ¿Eliminarías alguna columna? Justifica.

Actividad 2. Detectar faltantes con Pandas

Carga un dataset mediante Pandas y ejecuta:

```
print(df.isnull().sum())

porcentaje = df.isnull().mean() * 100
print(porcentaje)
```

Registra los resultados e identifica las tres variables con mayor cantidad de valores faltantes.

Actividad 3. ¿Eliminar o imputar?

Para cada situación decide qué estrategia sería más apropiada y explica por qué.

Situación	Decisión	Justificación
Una columna tiene 98 % de valores faltantes.		
Una variable numérica tiene 2 % de faltantes.		
Una variable categórica tiene 5 % de faltantes.		
Los faltantes aparecen principalmente en un grupo de clientes.		

Actividad 4. Media, mediana y moda

Crea una copia de tu dataset y realiza tres versiones diferentes de la imputación.

Versión 1 — Media:

```
media = df['edad'].mean()
df['edad'] = df['edad'].fillna(media)
```

Versión 2 — Mediana:

```
mediana = df['edad'].median()
df['edad'] = df['edad'].fillna(mediana)
```

Versión 3 — Moda para una variable categórica:

```
moda = df['plan'].mode()[0]
df['plan'] = df['plan'].fillna(moda)
```

Compara los resultados y explica cómo cambia el dataset en cada caso.

Actividad 5. Elegir entre media y mediana

Considera los siguientes valores de ingresos:

```
25000, 28000, 30000, 32000, 35000, 37000, 40000, 450000
```

- Calcula la media.
- Calcula la mediana.
- Compara ambos resultados.
- ¿Cuál utilizarías para imputar un valor faltante?
- Justifica tu elección.

Actividad 6. Imputación por grupos

Supón que tienes una variable de ingresos y otra que indica si el cliente pertenece al plan Básico o Premium.

Investiga los beneficios de utilizar una mediana diferente para cada grupo.

Implementa una solución utilizando:

```
df.groupby('plan')['ingresos'].transform(  
    lambda x: x.fillna(x.median())  
)
```

Explica por qué esta estrategia puede ser mejor que utilizar una única mediana para todos los clientes.

Actividad 7. SimpleImputer

Utiliza Scikit-learn para imputar una variable numérica mediante la mediana.

```
from sklearn.impute import SimpleImputer  
  
imputer = SimpleImputer(strategy='median')  
X_imputado = imputer.fit_transform(X)
```

Luego repite utilizando:

- strategy='mean'
- strategy='most_frequent'

Compara los resultados.

Actividad 8. KNNImputer

Investiga y aplica KNNImputer sobre un conjunto de variables numéricas.

```
from sklearn.impute import KNNImputer  
  
imputer = KNNImputer(n_neighbors=5)  
X_imputado = imputer.fit_transform(X)
```

Prueba diferentes cantidades de vecinos y observa si las estimaciones cambian.

Actividad 9. Imputación iterativa

Implementa una imputación utilizando IterativeImputer.

```
from sklearn.experimental import enable_iterative_imputer  
from sklearn.impute import IterativeImputer  
  
imputer = IterativeImputer(random_state=42)  
X_imputado = imputer.fit_transform(X)
```

Compara los valores obtenidos con los métodos anteriores.

Actividad 10. Detectar Data Leakage

Analiza las siguientes dos estrategias:

Estrategia A

1. Calcular la mediana de todo el dataset.
2. Dividir en entrenamiento y prueba.
3. Aplicar la mediana.

Estrategia B

1. Dividir en entrenamiento y prueba.
2. Calcular la mediana únicamente con entrenamiento.
3. Aplicar esa mediana a entrenamiento y prueba.

¿Cuál es correcta? ¿Por qué?

Actividad 11. Construir un Pipeline

Construye un pipeline que incluya:

- Imputación mediante mediana.
- Escalado mediante StandardScaler.
- Un modelo de clasificación.

Utiliza como referencia:

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression

pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler()),
    ('model', LogisticRegression())
])
```

Actividad 12. Comparar estrategias

Selecciona un dataset que contenga valores faltantes. Crea tres versiones del dataset:

- Versión A: eliminación de filas.
- Versión B: imputación mediante mediana.
- Versión C: imputación mediante KNN.

Compara:

- Cantidad de registros.
- Cantidad de valores faltantes.
- Distribución de las variables.
- Cambios en las estadísticas descriptivas.
- Resultado de un modelo sencillo.

Actividad Integradora — Limpieza profesional de un dataset**Consigna**

Selecciona un dataset relacionado con un problema de Machine Learning. Realiza un diagnóstico de sus valores faltantes y diseña una estrategia de limpieza e imputación justificada.

El trabajo debe incluir:

- 1. Descripción del dataset.
- 2. Cantidad de valores faltantes por variable.
- 3. Porcentaje de faltantes.
- 4. Análisis del posible origen de los faltantes.
- 5. Decisión sobre eliminación o imputación.
- 6. Aplicación de al menos dos estrategias de imputación.
- 7. Comparación de los resultados.
- 8. Análisis de posibles outliers afectados.
- 9. División entre entrenamiento y prueba.
- 10. Explicación de cómo se evitó el data leakage.
- 11. Pipeline de procesamiento.
- 12. Conclusiones.

Autoevaluación

1. ¿Qué es un valor faltante?

Respuesta: Una observación para la que no se dispone del valor correspondiente.

2. ¿Cómo se detectan valores faltantes con Pandas?

Respuesta: Mediante métodos como `isnull()` o `isna()`.

3. ¿Cuándo puede ser conveniente utilizar la mediana?

Respuesta: Cuando la variable numérica presenta asimetría o valores extremos.

4. ¿Qué estrategia suele utilizarse con variables categóricas?

Respuesta: La moda, aunque debe analizarse su conveniencia.

5. ¿Qué es KNNImputer?

Respuesta: Un método que utiliza observaciones similares para estimar faltantes.

6. ¿Qué es Data Leakage?

Respuesta: El uso indebido de información que no debería estar disponible durante el entrenamiento.

7. ¿Con qué datos debe ajustarse un imputador?

Respuesta: Con los datos de entrenamiento.

8. ¿Por qué utilizar un Pipeline?

Respuesta: Para integrar y reproducir correctamente las transformaciones y el modelado.

Cierre

Idea clave:

Los valores faltantes no deben tratarse automáticamente. Una estrategia profesional comienza por comprender por qué faltan los datos, medir su impacto y seleccionar una técnica de imputación que preserve la información sin introducir sesgos ni data leakage.