

MÓDULO 2 · MATERIAL 2

Aprendizaje Supervisado: Regresión y Clasificación

Material Teórico Completo • Fundamentos, Modelos y Conceptos Clave

En el Material 1 conocimos el concepto de Machine Learning y el flujo general de un proyecto. En este material comenzaremos a estudiar una de las principales formas de aprendizaje automático: el **aprendizaje supervisado**.

Aprenderemos cómo funcionan, a nivel introductorio, los problemas de regresión y clasificación, y conoceremos tres algoritmos fundamentales: **Regresión Lineal**, **Árboles de Decisión** y **k-Nearest Neighbors (k-NN)**.

El objetivo no es memorizar fórmulas ni implementar algoritmos complejos, sino comprender qué problema resuelve cada método, cómo utiliza los datos y qué tipo de resultado puede producir.

1. ¿Qué es el aprendizaje supervisado?

El aprendizaje supervisado es un tipo de Machine Learning en el que el modelo aprende utilizando datos que incluyen un resultado conocido. Podemos imaginarlo como aprender a partir de ejemplos.

Horas de estudio	Asistencia	Resultado
2	60 %	No aprueba
4	75 %	Aprueba
6	90 %	Aprueba
1	50 %	No aprueba

El modelo recibe: **Características** → **Resultado conocido**. Durante el entrenamiento intenta encontrar relaciones entre las características y el resultado. Después puede recibir un nuevo caso (ejemplo: *Horas: 5, Asistencia: 85 %*) y generar una predicción.

2. Dos grandes tipos de problemas

Regresión: Se utiliza cuando queremos predecir un valor numérico. Ejemplos: precio de una vivienda, temperatura, consumo de energía, tiempo de viaje, ventas de un producto.

Ejemplo: ¿Cuál será aproximadamente el precio de una vivienda de 100 m²? → **Resultado posible: \$210.000**

Clasificación: Se utiliza cuando queremos asignar un dato a una categoría o clase. Ejemplos: spam / no spam, aprobado / no aprobado, gato / perro, fraude / operación normal, riesgo alto / medio / bajo.

Ejemplo: ¿Este correo es spam? → **Resultado: Spam**

3. Regresión vs. Clasificación

Una forma sencilla de diferenciarlas es observar el tipo de resultado:


Regresión	Clasificación
Produce un valor numérico	Produce una categoría
Precio	Spam / No spam
Temperatura	Aprobado / No aprobado
Cantidad de ventas	Perro / Gato
Tiempo estimado	Riesgo alto / bajo

Regla sencilla: Si queremos estimar una cantidad → *regresión*. Si queremos elegir una categoría → *clasificación*.

4. Regresión lineal

Es uno de los métodos más sencillos para comprender cómo un modelo realiza predicciones numéricas mediante una línea recta.

Horas de estudio	Puntuación
1	45
2	50
3	58
4	65
5	72
6	78



Representación matemática: $y = mx + b$ (donde y es el valor predicho, x la característica, m la pendiente y b el intercepto).


5. Ejemplo cotidiano y Limitaciones

Supongamos una relación Publicidad (\$100 → \$1.000, \$200 → \$1.800, \$300 → \$2.500, \$400 → \$3.100). Una inversión prevista de \$500 producirá una estimación basada en patrones.

Limitaciones: Supone relaciones lineales. Las predicciones pueden verse afectadas por datos insuficientes/incorrectos, variables omitidas, valores atípicos y cambios de entorno.

6. Árboles de decisión

Un árbol de decisión utiliza preguntas estructuradas en raíz, nodos, ramas y hojas para tomar decisiones.



Ventajas: Fáciles de interpretar y seguir. **Limitaciones:** Si es muy complejo puede sobreajustarse (overfitting) a los datos de entrenamiento.

7. k-Nearest Neighbors (k-NN)

Clasifica un nuevo dato observando cuáles son los datos conocidos más cercanos ('vecinos'). La variable k define la cantidad de vecinos a evaluar (ej. $k=3$ o $k=5$).

8. Criterios de elección de algoritmos

La elección depende de: cantidad de datos, características disponibles, tipo de problema, rendimiento, interpretabilidad, tiempo de entrenamiento y recursos disponibles.

9. Glosario de Términos

Término	Definición
Aprendizaje supervisado	Tipo de ML que utiliza datos con resultados conocidos para entrenar un modelo.
Regresión	Tipo de problema en el que se busca predecir un valor numérico.
Clasificación	Tipo de problema en el que se busca asignar un dato a una categoría.
Regresión lineal	Método que busca representar una relación lineal entre variables.
Árbol de decisión	Modelo que utiliza condiciones organizadas en estructura de árbol.
k-NN	Algoritmo que utiliza los k datos más cercanos para predecir.
Característica	Variable utilizada como información de entrada para el modelo.
Etiqueta	Resultado conocido utilizado como referencia en el entrenamiento.
Predicción	Resultado generado por un modelo para nuevos datos.
Vecino	Dato considerado cercano a otro según medidas de distancia.