

ACTIVIDAD INTEGRADORA · MÓDULO 2

Primer proyecto de Machine Learning

Guía de desarrollo e integración práctica

Consigna: En esta actividad vas a integrar los conocimientos trabajados durante el módulo para desarrollar, de forma guiada, tu primer proyecto de Machine Learning. El objetivo es analizar un conjunto de datos, prepararlo para trabajar con un modelo, realizar predicciones y evaluar sus resultados.

Situación: Una institución educativa quiere analizar el desempeño de sus estudiantes y utilizar Machine Learning para predecir si un estudiante podría aprobar o desaprobado un curso. Para realizar esta tarea se dispone de los siguientes datos:

Estudiante	Horas de estudio	Asistencia (%)	Actividades entregadas	Resultado
Ana	8	95	9	Aprobado
Bruno	6	85	8	Aprobado
Carla	3	70	5	Desaprobado
Diego	9	98	10	Aprobado
Elena	—	60	4	Desaprobado
Facundo	5	80	7	Aprobado
Gabriela	1	55	3	Desaprobado
Hugo	7	90	8	Aprobado
Irene	4	72	5	Desaprobado
Joaquín	6	88	7	Aprobado
Joaquín	6	88	7	Aprobado
Karen	20	65	4	Desaprobado
Lucas	8	92	9	Aprobado

Observa que el conjunto de datos contiene algunos problemas que deberán ser identificados y analizados antes de utilizarlo.

1. Comprender el problema

Identifica:

- ¿Cuál es el objetivo del proyecto?
- ¿Cuál es la variable que queremos predecir?
- ¿Qué variables pueden utilizarse como características?
- ¿Se trata de un problema de regresión o de clasificación? Explica por qué.

2. Analizar y limpiar los datos

Examina el conjunto de datos e identifica al menos:

- Un dato faltante.
- Un registro duplicado.
- Un valor que podría considerarse un dato atípico o posiblemente incorrecto.

Explica qué decisión tomarías en cada caso y por qué.

Importante: Un dato atípico no debe eliminarse automáticamente. Primero debemos analizar si representa un error o una situación real.

3. Preparar los datos

Indica qué transformaciones serían necesarias para que los datos puedan utilizarse en un modelo de Machine Learning. Considera aspectos como: datos faltantes, duplicados, atípicos, variables numéricas, categóricas y la separación entre entrenamiento y prueba.

4. Entrenar un modelo

Selecciona un algoritmo de clasificación estudiado en el módulo (por ejemplo, un árbol de decisión) y explica brevemente por qué puede utilizarse para este problema.

5. Realizar predicciones

Supongamos que recibimos los datos de dos nuevos estudiantes:

Estudiante	Horas de estudio	Asistencia (%)	Actividades entregadas
Estudiante A	6	85	8
Estudiante B	2	60	3

Utilizando la información disponible y el modelo planteado, indica qué resultado esperarías para cada estudiante (Aprobado / Desaprobado) y explica brevemente tu razonamiento.

6. Evaluar el modelo

Supongamos que, al evaluar el modelo sobre un conjunto de prueba, obtenemos los siguientes resultados en la matriz de confusión:

	Predijo Aprobado	Predijo Desaprobado
Real: Aprobado	4	1
Real: Desaprobado	1	4

Considerando '**Aprobado**' como la clase positiva, identifica: Verdaderos positivos (TP), Verdaderos negativos (TN), Falsos positivos (FP) y Falsos negativos (FN). Luego calcula las métricas:

$$\text{Precisión} = \text{TP} / (\text{TP} + \text{FP}) \quad | \quad \text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

7. Interpretar los resultados

- ¿Qué significa que el modelo haya cometido falsos positivos?
- ¿Qué significa que haya cometido falsos negativos?
- ¿Por qué es importante analizar los errores del modelo?
- ¿Por qué no sería conveniente utilizar un modelo sin evaluar previamente sus resultados?

8. Reflexión final

Responde con tus propias palabras:

- ¿Por qué es importante limpiar y preparar los datos antes de entrenar un modelo?
- ¿Qué podría ocurrir si utilizamos datos incorrectos o incompletos?
- ¿Por qué debemos separar los datos de entrenamiento de los datos de prueba?
- ¿Qué información aporta una matriz de confusión?
- ¿Qué diferencia existe entre precisión y recall?
- ¿Consideras que un modelo de Machine Learning debería tomar por sí solo la decisión final sobre si un estudiante aprueba o desaprueba? Fundamenta tu respuesta.
- ¿Qué otros datos podrían incorporarse al proyecto para intentar mejorar el análisis?

Entrega y Producto Esperado

Presenta un informe breve que contenga: Descripción del problema, Identificación de variables, Análisis y limpieza de los datos, Preparación de los datos, Modelo seleccionado, Predicciones, Evaluación, Interpretación de resultados y Reflexión final.

Flujo completo del proyecto:

Problema → Datos → Limpieza → Preparación → Entrenamiento → Predicción → Evaluación → Interpretación

No es necesario desarrollar un sistema complejo. Lo importante es comprender y explicar cada etapa de un proyecto de Machine Learning y justificar las decisiones tomadas.