

MÓDULO 2 · MATERIAL 3

Aprendizaje No Supervisado: Clustering y Reducción de Dimensionalidad

Material Teórico • Fundamentos, Algoritmos y Aplicaciones

Descripción: En los materiales anteriores estudiamos qué es Machine Learning y cómo funcionan algunos métodos de aprendizaje supervisado, donde los datos contienen información sobre el resultado esperado. En este material conoceremos el aprendizaje no supervisado, donde el sistema trabaja con datos sin etiquetas previas para descubrir estructuras, grupos y patrones no evidentes a simple vista.

Objetivos de aprendizaje:

- Explicar qué es el aprendizaje no supervisado y diferenciarlo del supervisado.
- Comprender el concepto de clustering y la técnica K-Means a nivel introductorio.
- Reconocer aplicaciones prácticas del agrupamiento en diferentes dominios.
- Comprender qué es la reducción de dimensionalidad (PCA) y para qué se utiliza.

1. ¿Qué es el aprendizaje no supervisado?

En el aprendizaje supervisado, el modelo recibe ejemplos en los que conocemos el resultado esperado (por ejemplo, relacionar *Horas de estudio* y *Asistencia* con un *Resultado* de Aprobado/No Aprobado). En el aprendizaje no supervisado, en cambio, no tenemos esa columna de resultado.

Horas de estudio	Asistencia	Resultado (Supervisado)
2	60%	No aprobado
5	80%	Aprobado
8	95%	Aprobado

Si eliminamos la etiqueta de resultado, el algoritmo no supervisado debe intentar encontrar alguna estructura dentro de los datos (por ejemplo, descubrir que existen grupos de estudiantes con características similares).

Idea principal: En el aprendizaje no supervisado, el modelo busca patrones o estructuras en los datos sin disponer de etiquetas previamente conocidas.

2. Supervisado vs. no supervisado


Característica	Supervisado	No supervisado
¿Tiene etiquetas?	Sí	No
¿Conoce el resultado?	Sí	No
Objetivo	Predecir	Encontrar patrones
Ejemplo	Detectar spam	Agrupar clientes
Técnicas	Regresión, clasificación	Clustering, reducción de dimensionalidad

3. ¿Qué es el clustering?

Clustering (o agrupamiento) es una técnica que busca dividir un conjunto de datos en grupos cuyos elementos tengan características similares. Cada grupo recibe el nombre de **cluster**. Los grupos no son definidos por una persona, sino descubiertos a partir de datos como edad, frecuencia de compra o gasto.

4. Una representación sencilla

Podemos representar visualmente a los individuos en un plano cartesiano (Edad vs. Gasto Mensual). Los puntos cercanos forman concentraciones de datos que el clustering intenta identificar automáticamente:



5. Algoritmo K-Means

Es uno de los algoritmos de clustering más conocidos. La letra **K** representa la cantidad de grupos elegida (ej. $K=3$). La palabra *Means* hace referencia a la media o promedio. K-Means intenta encontrar un punto representativo para cada grupo, llamado **centroide**.

6. ¿Cómo funciona K-Means?

Paso 1: Elegir K. Decidir cuántos grupos se desea formar (ej. $K = 3$).

Paso 2: Ubicar centroides iniciales. El algoritmo establece K puntos provisionales en el espacio.

Paso 3: Asignar datos al centroide más cercano. Cada punto se asocia a su centroide próximo.

Paso 4: Recalcular centroides. Se calcula la posición central real de los puntos asignados a cada grupo.

Paso 5: Repetir. El proceso se itera hasta que los grupos dejan de cambiar significativamente.

7. Ejemplo y elección del número K

En un análisis de clientes con $K=3$, K-Means podría segmentar: *Grupo 1 (Bajo gasto/poca frecuencia)*, *Grupo 2 (Gasto medio/frecuencia alta)* y *Grupo 3 (Alto gasto/frecuencia alta)*. La interpretación del significado de cada grupo la realiza posteriormente el especialista.

Para elegir K se suele utilizar el **método del codo**: se evalúa cómo cambia el error interno del agrupamiento al variar K ; cuando aumentar K deja de producir mejoras importantes, se identifica un punto similar a un 'codo'.

8. Aplicaciones del clustering

- **Segmentación de clientes:** Agrupar usuarios según hábitos de consumo o gasto.
- **Agrupamiento de documentos:** Clasificar textos automáticamente por temática (deportes, economía, tecnología).
- **Análisis de imágenes y recomendación:** Detectar regiones con características similares o identificar patrones de comportamiento entre usuarios.
- **Detección de anomalías:** Identificar comportamientos que se alejan significativamente de los patrones habituales.

9. Clustering no es Clasificación

En **clasificación** las categorías ya están previamente definidas (ej. Correo → Spam / No Spam). En **clustering** las categorías NO existen de antemano; el algoritmo descubre las agrupaciones presentes en los datos.

10. Reducción de dimensionalidad y PCA

Cuando un dataset contiene decenas o cientos de características (edad, ingresos, compras, tiempo de sesión, etc.), decimos que tiene alta dimensionalidad. La **reducción de dimensionalidad** busca representar los datos con menos variables conservando la mayor cantidad de información relevante.

Una técnica fundamental es **PCA (Análisis de Componentes Principales)**, la cual transforma múltiples características originales en un número menor de componentes principales que resumen la variabilidad de los datos.

Glosario de conceptos

Concepto	Definición
Aprendizaje No Supervisado	Enfoque de ML que busca patrones o estructuras sin etiquetas conocidas.
Clustering	Técnica para agrupar datos según su similitud.
K-Means / Centroide	Algoritmo de agrupamiento basado en K centroides que representan el centro de cada grupo.
Reducción de Dimensionalidad	Proceso de representar datos complejos utilizando menos dimensiones/variables.
PCA	Análisis de Componentes Principales. Transforma variables originales en componentes principales sintetizados.