

MÓDULO 2 · MATERIAL 5

Preparación y Limpieza de Datos en Machine Learning

Material Teórico • Fundamentos, Preprocesamiento, Codificación y Escalado

Descripción: Un modelo de Machine Learning aprende directamente de los datos recibidos. Si contienen valores faltantes, duplicados, errores, formatos inconsistentes o escalas dispares, el modelo aprenderá patrones incorrectos. En este material abordamos las técnicas fundamentales para identificar y resolver estos problemas antes del entrenamiento.

Objetivos de aprendizaje:

- Comprender la importancia de la limpieza y preparación de datos (Data Preprocessing).
- Identificar estrategias para tratar datos faltantes, duplicados, valores incorrectos y atípicos.
- Diferenciar entre variables numéricas y categóricas, y aplicar técnicas de codificación (Label / One-Hot Encoding).
- Entender las técnicas de escalado (Normalización Min-Max y Estandarización Z-score).
- Comprender el flujo correcto de división de datos y cómo prevenir la fuga de información (Data Leakage).

Demostración Práctica del Preprocesamiento

Estudiante	Edad	Modalidad	Horas
Ana	20	Presencial	8
Luis	22	Virtual	5
Marta	21 (Imputado)	Presencial	7
Juan	21	Virtual	3